HW1

R14H41007 統計碩士學位學程一石欽鈺

March 28, 2026

Q1 針對這兩張圖，我想分成 radius、variance、$bias^2$ 和 MSE 四個層面討論：

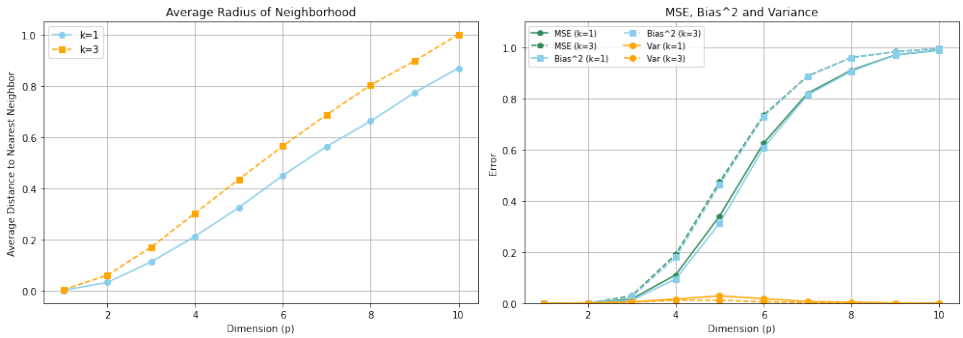

Radius. 先關注 x 軸，可以明顯發現課本中強調高維度下 knn 的弱點顯現了，也就是鄰域已不再具有局部性。不過，我們從左圖兩條線可以發現，局部性的崩潰速度並不同，因爲回顧課本中的公式，半徑是以 $e_p(k) \propto (k/N)^{1/p}$ 的速率增長，所以在不同的 k 下，即使是同一個維度，所需的半徑有著可被量化的不同，當 k 越大，半徑擴增的速度越快，尤其題目設定是在 p-維 unit hypercub，當 average distance 已經趨近於邊長甚至要等於邊長時，代表他已經觸及了近乎全域，knn 的意義此時已不具。

Variance. 移至右圖，很明顯的有 bias-variance tradeoff 的情況。先從 variance 來討論，變異數一直都偏低，且 k=1 與 k=3 有著雷同的趨勢，些微差異是 k=1 在中等維度（p=4 to 6) 時的波動幅度較大。他們共同的情況：(1) 在低維度時，由於在很小的範圍內灑了 1000 個點，所以原點 0 的附近很容易有鄰居，因此每一次 knn 算出來的 y 都會很接近 1，推得變異小的原因。(2) 中間維度時，情況就順勢的因為撒點範圍變大，點之間的距離也變寬，產生的變異因此更高。(3) 高維時變異反而又趨於零，但如老師上課所說這並不是一個好現象，因為這是極大多數 y 都一致的錯誤預測成 0，所以沒有什麼變異，簡單來說就是高維下 knn 已失去作用，預測全錯。比較 k=1 and k=3: 前面有說些微差異是 k=1 在中等維度（p=4 to 6) 時的波動幅度較大。因為 k=1 時，預測值完全取決於最近的「那一個」點，所以當維度越高，點密度越低，那麼取到的點之間座標差異可能越大，但 k=3 時，是三點平均起來，所以可以去綜合調一些比較極端的情況，讓整體預測值不會太過多樣化。

Bias^2. 從低到高維大幅增加了 Bias^2，原因即為前面提及的點稀疏度增加。特別注意 k=3 較 k=1 提前增加更多誤差，因為 k=1 就是只看最接近的那一個點，所以誤差自然很小，k=3 時必須一次平均三個點的值，那麼當空間中點越稀疏（也就是維度越大），選最近的三個點時變越容易找到更遠、更不準的點來平滑整體，代價就是越大的 bias。

針對 Bias^2 的增長速度可知 p=1～3 的時候是相對緩慢的，這個我們討論變異數時提到第一點「低維時，在很範圍灑了 1000 個點，原點附近很容易有鄰居」有關。在 p=4～7 時，增場速度大幅增加，搭配左圖可看出半徑從 0.2 增加至 0.6，推估在這些空間下半徑增加一些些就是造成點分配的稀疏度大增，函數在這裡變動的應該最劇烈！維度到了最高階段時，我認為是已趨近飽和以致偏差增長減緩，預測值幾乎等於 0 了，就算維度再增、預測值頂多是從 0.01 變成 0.001，對 Bias^2 的貢獻已微乎其微。

MSE. Bias^2 與變異數的總和：

$$\mathrm{MSE}(x_0) = E_{\mathcal{T}}[(f(x_0) - \hat{y}_0)^2] = \underbrace{[f(x_0) - E_{\mathcal{T}}(\hat{y}_0)]^2}_{\text{Bias}^2} + \underbrace{E_{\mathcal{T}}[(\hat{y}_0 - E_{\mathcal{T}}(\hat{y}_0))^2]}_{\text{Variance}} \tag{1}$$

又以 Bias^2 的影響佔比大於變異數，所以他的趨勢跟我們討論 Bias^2 的情況差不多，尤其看看高維時 MSE 與 Bias^2 的曲線幾乎重合，但那時候變異數是趨近於 0 的，可知總誤差基本上來自 Bias^2。最後，總誤差趨近於 1，告訴我們：高維時這個模型已經失去預測能力了，平滑化（增加 k）不但救不了模型，反而會讓 MSE 更快達到失敗的飽和點。

Q2 我用了 1000 次蒙地卡羅模擬，單次實驗樣本數為 $N = 500$。

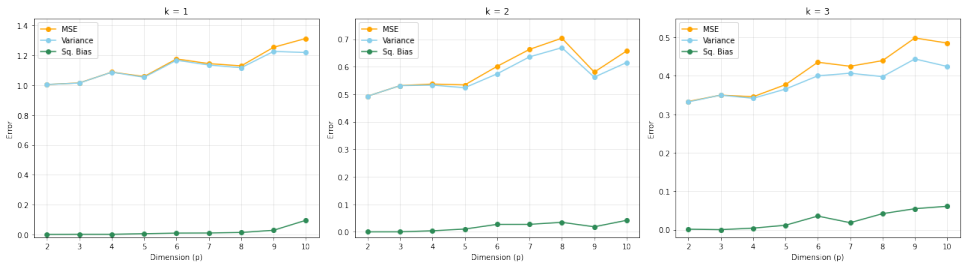

對比第一題，當影響變數只關注兩個時，在任何維度下 Bias^2 都小了非常多，多至低於變異數，這是在一次看好幾個變數下相反的情況。因為一個軸發生一點偏差，十個軸的偏差堆疊起來就變得很可觀; 反之，若只關注一個軸，那偏差不會那麼浮誇。不過變異數的部分就比較高，當真正重要的變數變成只有一個，但決策時又會受到其餘好幾個變數（$X_3 \sim X_{10}$）的影響，導致無用的雜訊扭曲了距離計算，模型極度不穩定。因此，變異數隨著維度，整體趨勢往上搭配不斷波動，推測由於 $f(X)$ 在 X_2 方向是三次方成長，因此 X_2 微小的座標變動都能使預測值大幅改變，無論在哪個 k 設定下都一樣。

總合三張圖來看，隨著 k 增加 Y 軸刻度呈現顯著下降（$k = 1$ 時 Y 軸最高可達 1.4，而 $k = 3$ 時下降到了約 0.5），這個原因我認為也是因為 k=1 時並沒有做平滑，導致過度敏感，目標函數中有三次方項意，所以假設 k=1 抓到的鄰近點在 X_2 軸上稍微偏了一點，預測值落差會被放大。這些內容不斷展謝集體智慧的概念。這邊的 trade-off 是 k 讓 bias 增加，但對於這個函數，變異數下降的速度遠快於 bias 的上升。

MSE 曲線幾乎與 Variance 曲線重合，代表在高維度雜訊環境下，若真實函數僅依賴少數有效維度，Bias 不再是主要威脅，我們一開始有提到這個觀點。總地來說，MSE 的增長本質上是模型不穩定性的累積，而非結構性預測錯誤的堆疊。

k 值此時好像能看作最佳化 MSE 的工具，因為增加 k 帶來的輕微偏誤，附加著大幅縮減的 variance ，帶來的效益遠超偏誤增加的代價。

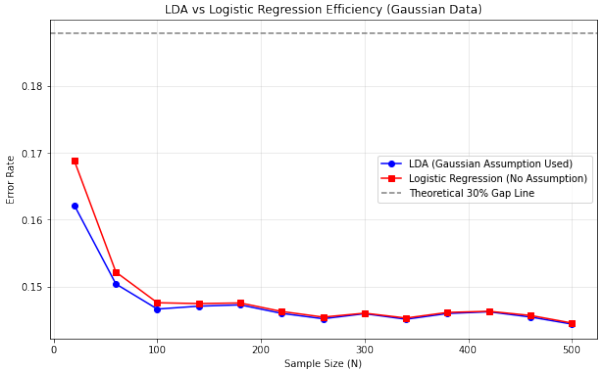

Optional. 我們在訓練資料完全符合 LDA 假設（$fk(x)$ 為 Gaussian 且共用 Σ）的環境下進行測試：

LDA 使用 full likelihood，包含資料的邊際分佈 P(X). 它假設 X 是由兩個共用共變異矩陣的 gaussion dist. 混合而成。代表比起 logistic regression 學習怎麼分界，LDA 還在學習資料長相。而圖片結果顯示，這在小樣本下（資訊比較缺乏），正確的模型假設能有效降低估計的 error rate。果然 LDA 很適合這個實驗設定。不過隨著樣本變大，兩者都收斂到 error rate 低於 0.15，趨於穩定的表現，Efron 在論文中有用漸 asymptotic relative efficiency，證明樣本數無限大時，兩者都會收斂到相同的 bayes error rate (理論最優)。而 LDA 也展現也正如 Efron 講的，雖然 logistic regression 不必依賴分布假設，相對 robust，但在資料確實服從高斯分佈的理想情況下，其對資訊的浪費會導致效率損失。但反面，就是當實驗設定變成不符合常態或是有些離群值去影響結果的話，依據 Efron 的觀點，logistic regression 的效率損失將會被其穩健性補償，且大樣本下邏輯斯回歸並沒有失利，因為它仰賴大量的點來反覆調整那一條線的位置，而大樣本能滿足這個條件。

由於我認為上圖不能明顯看出收斂速度，所以再寫了一段程式看看實際數值，如下表：

Table 1: 錯誤率下降速率對比

樣本區間	LDA 下降速率	LogReg 下降速率
20 → 60	-0.000293	-0.000414
60 → 100	-0.000094	-0.000114
100 → 140	0.000011	-0.000003
140 → 180	0.000005	0.000002
180 → 220	-0.000032	-0.000032
220 → 260	-0.000020	-0.000021
260 → 300	0.000019	0.000015
300 → 340	-0.000021	-0.000018
340 → 380	0.000021	0.000021
380 → 420	0.000006	0.000004
420 → 460	-0.000019	-0.000016
460 → 500	-0.000026	-0.000028

很明顯的樣本 20-60 時，兩者下降速率都是所有區間中最快的，代表一點點樣本增加，就能對錯誤率有可觀的影響。到了 60-100 時，雖然邏輯斯回歸有更高速的下降，但可想而知那也是因為邏輯斯一開始的錯誤率就是比較高。大約超過一百個樣本以後，下降率就變得相對緩慢，皆縮小至 10^{-5} 數量級，這樣應該象徵快到理論最低錯誤率的

臨界值了。這樣的資訊或許對未來要收集多少樣本是相當重要的，因為資訊在某個時刻已經達到了飽和。這結果精確量化 Efron 提的：Logistic Regression 由於忽略了邊際可能性（Marginal Likelihood）的資訊，在樣本效率上存在顯著的漸進損耗。LogReg 在初期必須跑得比 LDA 更快（下降率絕對值更大），是為了追趕 LDA 憑藉「事前情報」所取得的起跑優勢。